



Dipartimento di ingegneria informatica, modellistica,
elettronica e sistemistica

Corso di Laurea Magistrale in Ingegneria Informatica

Relazione Information Retrieval e Natural Language Processing

Analisi di modelli linguistici generativi per la generazione di
risposte psicologiche, con tecniche di clustering semantico,
sentiment analysis, classificazione e fine-tuning.

Docente:

Prof. Andrea Tagarelli

Studenti:

Di Pane Gomez Miguel Angel

Montalto Antonio Angelo

Anno Accademico 2024/2025

Indice

1	Introduzione	3
2	Il dataset	3
2.1	Preprocessing	3
3	Clustering Semantico e Sentiment Analysis	3
3.1	Procedura	4
3.2	Risultati ottenuti	7
4	Classificazione delle risposte	8
5	Generazione delle risposte pre-finetuning	10
5.1	Risposte generate	14
5.1.1	Generazione risposte Qwen	15
5.1.2	Generazione risposte Meta-LLama	16
5.1.3	Generazione risposte Gemma3	17
5.2	Valutazione delle risposte generate	18
6	Finetuning Modelli	22
6.1	Modello Qwen 2.5	24
6.1.1	Metriche di Valutazione	24
6.2	Modello Llama 3.2	27
6.2.1	Metriche di Valutazione	27
6.3	Modello Gemma3	30
6.3.1	Metriche di Valutazione	30
7	Conclusioni	33

1 Introduzione

L'obiettivo di questo progetto è analizzare e sperimentare l'utilizzo di modelli di linguaggio generativo per la generazione di risposte psicologiche, a partire da un dataset di conversazioni reali tra pazienti e psicologi. In particolare, il lavoro mira a valutare come diverse tecniche di prompt engineering e di fine-tuning influenzino la qualità delle risposte, misurata attraverso metriche automatiche e analisi semantiche. Lo scopo finale è comprendere in che modo i modelli possano produrre risposte empatiche, naturali e clinicamente pertinenti, avvicinandosi allo stile comunicativo degli psicologi umani e migliorando così il potenziale applicativo degli LLM nel contesto del supporto psicologico.

2 Il dataset

Il dataset *mental_health_counseling_conversations* [2] utilizzato in questo progetto è una raccolta di domande e risposte in lingua inglese provenienti da due piattaforme online dedicate al supporto psicologico e alla consulenza terapeutica. Le domande coprono un ampio spettro di tematiche legate alla salute mentale e le risposte sono fornite da psicologi qualificati. Lo scopo principale del dataset è quello di essere impiegato per il fine-tuning di modelli linguistici, con l'obiettivo di migliorarne la capacità di fornire consigli e supporto in ambito psicologico.

Ogni istanza del dataset è costituita da due campi principali: **Context** e **Response**. Il campo **Context** contiene la domanda posta da un utente, mentre il campo **Response** contiene la risposta fornita dallo psicologo.

I dati grezzi sono stati sottoposti a un'accurata pulizia, mantenendo esclusivamente i contenuti conversazionali rilevanti. Inoltre, tutti i dati sono stati anonimizzati e non contengono alcuna informazione che possa identificare personalmente gli utenti.

2.1 Preprocessing

Per preparare i dati all'addestramento del modello, è stata effettuata una fase di preprocessing volta a rimuovere elementi indesiderati e garantire la coerenza dei testi. In primo luogo, sono state eliminate tutte le istanze in cui almeno uno tra il campo **Context** o il campo **Response** risultava mancante o nullo.

Successivamente, sono stati rimossi i caratteri di nuova riga (`\n`) presenti nei testi. Questa pulizia ha interessato entrambe le colonne, con l'obiettivo di ottenere frasi più leggibili e di facilitare l'elaborazione da parte del modello di linguaggio. I testi risultanti sono quindi compatti, privi di interruzioni di linea e adatti al processo di tokenizzazione.

3 Clustering Semantico e Sentiment Analysis

Il **Clustering Semantico** è una tecnica di raggruppamento che organizza dati testuali in gruppi (cluster) basati sul significato e sul contenuto semantico delle informazioni, piuttosto che sulla semplice corrispondenza lessicale o sintattica. Utilizzando modelli di

linguaggio avanzati e rappresentazioni vettoriali del testo (come gli embedding), il semantic clustering identifica similarità tra frasi o documenti, permettendo di aggregare insieme elementi che trattano concetti affini, anche se espressi con parole diverse.

La **sentiment analysis** è una tecnica di elaborazione del linguaggio naturale che consiste nell'identificare e classificare automaticamente le opinioni, le emozioni o l'atteggiamento espresso in un testo, tipicamente in categorie come positivo, negativo o neutro. Questa analisi è ampiamente utilizzata per comprendere il sentimento degli utenti in recensioni, social media, o altre comunicazioni testuali.

L'applicazione del semantic clustering alla lista di domande poste dai pazienti agli psicologi ha lo scopo di individuare temi ricorrenti e raggruppare richieste affini, migliorando la comprensione del dataset sotto studio. Inoltre, riducendo la complessità dei dati testuali, si cerca di evidenziare pattern nascosti e trend nelle domande. La sentiment analysis, integrata a questo approccio, permette inoltre di cogliere le sfumature emotive presenti nelle richieste, offrendo una comprensione più profonda dello stato d'animo dei pazienti.

3.1 Procedura

Dati considerati: Per questo analisi è stata effettuata una selezione delle domande uniche presenti nel dataset, escludendo tutte quelle ripetute.

```
1 domande_counts = df['Context'].value_counts()
2 unique_domande = domande_counts[domande_counts == 1].index
3 df_domande = df[df['Context'].isin(unique_domande)][['Context']].
    reset_index(drop=True)
```

Rappresentazione vettoriale: Per rappresentare semanticamente le domande uniche, è stato utilizzato il modello **all-MiniLM-L6-v2**. Questo è un modello di sentence-transformers che mappa frasi e paragrafi in uno spazio vettoriale denso a 384 dimensioni, producendo un vettore (embedding) che cattura l'informazione semantica e può essere utilizzato per task come clustering, ricerca semantica, recupero di informazioni o misura della similarità tra frasi [5].

```
1 model = SentenceTransformer('all-MiniLM-L6-v2')
2 embeddings = model.encode(df_domande['Context'].tolist())
```

Riduzione dimensionale: Per facilitare e ottimizzare il processo di clustering, è stata applicata una riduzione dimensionale sugli embeddings tramite l'algoritmo PCA (Principal Component Analysis), limitando il numero di componenti a cinque. Questo passaggio serve a condensare le informazioni più rilevanti in un numero ridotto di variabili, eliminando rumore e ridondanza, e migliorando così l'efficienza computazionale e la qualità del clustering.

```
1 # PCA per KMeans
2 pca = PCA(n_components=5)
3 reduced_KMeans = pca.fit_transform(embeddings)
```

Algoritmo di clustering: È stato utilizzato l'algoritmo KMeans con 3 cluster, un numero definito sulla base di vari tentativi preliminari, al fine di raggruppare al meglio le domande in categorie distinte. Ciascuna domanda è stata quindi assegnata a uno di questi cluster, permettendo un'analisi più strutturata dei temi emergenti nel dataset.

```

1 # KMeans
2 n_clusters = 3
3 kmeans = KMeans(n_init='auto', n_clusters=n_clusters, random_state=42)
4 labels = kmeans.fit_predict(reduced_KMeans)
5 df_domande['cluster'] = labels


```

Per visualizzare graficamente i risultati del clustering, è stata applicata una riduzione dimensionale degli embeddings utilizzando la PCA con due componenti principali. Questa trasformazione ha permesso di rappresentare le domande in uno spazio bidimensionale, facilitando la visualizzazione dei cluster ottenuti con KMeans. Successivamente, è stato generato un grafico scatter in cui ogni punto rappresenta una domanda e il colore indica il cluster di appartenenza.

```

1 # PCA per visualizzazione
2 pca = PCA(n_components=2)
3 reduced = pca.fit_transform(embeddings)

```



Keywords: Per l'estrazione delle parole chiave di ogni cluster, è stata implementata la seguente pipeline.

1. Conversione delle contrazioni in forma estesa, per esempio I'm → I am.
2. Applicazione di un **tokenizer custom** con assegnazione delle parti del discorso (POS tagging). Si è applicato un filtro per mantenere solo sostantivi di lunghezza superiore a due caratteri, escludendo le parole di una lista personalizzata di stopword ritenute poco significative nel contesto clinico, come termini generici o troppo frequenti (es. "thing", "life", "time"). Ogni parola è stata poi lemmatizzata per ridurne la variabilità.
3. Estrazione delle 10 parole chiave più rappresentative tramite TF-IDF, utilizzando il tokenizer personalizzato con filtraggio delle stopwords e lemmatizzazione.

Sentiment Analysis: Approfittando del ciclo for utilizzato per la determinazione delle keywords, è stato calcolato il sentiment per ogni frase all'interno di ciascun cluster mediante la libreria **TextBlob**. Questa libreria consente di categorizzare le domande dei pazienti come positive, negative o neutre in base alla polarità.

```

1 lemmatizer = WordNetLemmatizer()
2
3 # Lista stopwords personalizzata da escludere
4 custom_stopwords = set([
5     "thing", "anything", "lot", "time",
6     "year", "people", "someone", "something",
7     "life", "month", "point", "way", "issue",
8     "interest", "nothing", "problem", "everything",
9     "day"
10 ])
11
12 # Mappa i tag Penn Treebank a WordNet
13 def penn_to_wordnet(tag):
14     if tag.startswith('N'):
15         return wordnet.NOUN
16     else:
17         return None
18
19 # Espande contrazioni
20 def expand_contractions(text):
21     return contractions.fix(text)
22
23 # Tokenizer con POS tagging, filtro, lemmatizzazione e stopwords
24 def custom_tokenizer(text):
25     text = text.lower()
26     tokens = word_tokenize(text)
27     tagged_tokens = pos_tag(tokens)
28
29     lemmatized = []
30     for word, tag in tagged_tokens:
31         if len(word) > 2 and word not in custom_stopwords:
32             wn_tag = penn_to_wordnet(tag)
33             if wn_tag == wordnet.NOUN:
34                 lemma = lemmatizer.lemmatize(word, pos=wn_tag)
35                 if lemma not in custom_stopwords:
36                     lemmatized.append(lemma)
37
38     return lemmatized
39
40
41 # Analisi qualitativa per ogni cluster
42 all_data = []
43
44 for cluster_id in range(n_clusters):
45     cluster_domande = df_domande[df_domande['cluster'] == cluster_id]['Context'].tolist()
46
47     # Espandi contrazioni
48     cluster_domande = [expand_contractions(t) for t in cluster_domande]
49
50     # TF-IDF e parole chiave
51     tfidf = TfidfVectorizer(tokenizer=custom_tokenizer, lowercase=True,
52                             max_features=10, token_pattern=None)
53     tfidf_matrix = tfidf.fit_transform(cluster_domande)
54     keywords = tfidf.get_feature_names_out()
55
56     # Mostra info cluster
57     cluster_title = f"Cluster {cluster_id} ({len(cluster_domande)} domande)"

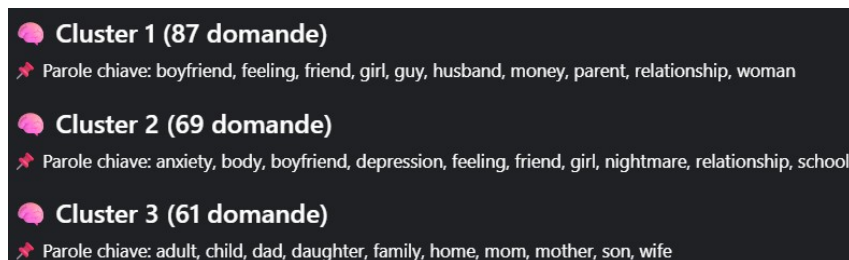
```

```

17 keyword_line = f"Parole chiave: {' ', ' '.join(keywords)}"
18 display(Markdown(f"### {cluster_title}"))
19 display(Markdown(f"{keyword_line}"))
20
21 # Calcola sentiment per ogni frase nel cluster
22 for text in cluster_domande:
23     polarity = TextBlob(text).sentiment.polarity
24     sentiment = 'positivo' if polarity > 0 else 'negativo' if
25 polarity < 0 else 'neutro'
    all_data.append({'cluster': cluster_id, 'sentiment': sentiment})


```

3.2 Risultati ottenuti



- **Cluster 1:** Si concentra su tematiche relazionali e personali, in particolare rapporti sentimentali e familiari. Emergono anche riferimenti ai sentimenti e alle relazioni sociali. Alcune conversazioni includono aspetti economici legati a queste dinamiche.
- **Cluster 2:** Riguarda soprattutto aspetti psicologici e di benessere mentale, con riferimenti a ansia, depressione e stati emotivi complessi. Le preoccupazioni emergono spesso in contesti sociali e relazionali. Sono presenti anche richiami al corpo e all'ambiente scolastico, legati al contesto di vita degli interlocutori.
- **Cluster 3:** È centrato sulle relazioni familiari e generazionali, con attenzione ai ruoli all'interno del nucleo domestico. Emergono temi legati a figli, genitori e vita coniugale. Alcune conversazioni riguardano anche il contesto abitativo e le responsabilità adulte.

I dati relativi a cluster e sentiment sono stati aggregati in un unico grafico a barre combinato per mostrare la distribuzione dei sentimenti all'interno di ciascun cluster.



4 Classificazione delle risposte

In questa fase successiva all'analisi semantica e clustering delle domande dei pazienti, si è affrontata la classificazione delle risposte fornite dagli psicologi, con l'obiettivo di individuare il possibile disturbo del paziente.

Per definire le etichette per la classificazione si è utilizzato un dataset contenente una lista di disturbi mentali. Questo dataset è stato costruito facendo riferimento al Manuale Diagnostico e Statistico dei Disturbi Mentali (DSM) [1], pubblicato dall'American Psychiatric Association (APA). Questo manuale rappresenta un punto di riferimento internazionale per la classificazione e la diagnosi dei disturbi mentali, fornendo un linguaggio comune e criteri standardizzati.

```
1 mental_disorders_df = pd.read_csv('/kaggle/input/mental-disorders/
   mental_disorders.csv')
2 mental_disorders_list = mental_disorders_df["Mental Disorder"].tolist()
3 mental_disorders_str = ", ".join(mental_disorders_list)
```

Per la classificazione delle risposte fornite dagli psicologi, è stato impiegato un modello di linguaggio generativo chiamato **OpenChat 3.5** [8], caricato utilizzando la libreria Hugging Face Transformers. Il modello è stato ottimizzato per l'esecuzione su GPU attraverso una configurazione di quantizzazione a 4 bit (BitsAndBytesConfig), che consente una riduzione significativa del consumo di memoria mantenendo prestazioni adeguate per il task. Questo modello è stato selezionato per la sua capacità di comprensione contestuale delle risposte e per la compatibilità con prompt strutturati in linguaggio naturale, utili per associare ogni risposta al disturbo mentale più plausibile.

```
1 device = torch.device("cuda") if torch.cuda.is_available() else torch.
   device("cpu")
```



```

2
3 model_name = "openchat/openchat-3.5-0106"
4 quantization_config = BitsAndBytesConfig(
5     load_in_4bit=True,
6     bnb_4bit_compute_dtype=torch.float16,
7     bnb_4bit_use_double_quant=True,
8     bnb_4bit_quant_type="nf4"
9 )
10
11 classification_model = AutoModelForCausalLM.from_pretrained(
12     model_name,
13     device_map="auto",
14     quantization_config=quantization_config)
15 tokenizer = AutoTokenizer.from_pretrained(model_name)
16
17 if tokenizer.pad_token is None:
18     print("Tokenizer has no pad token.")
19     tokenizer.pad_token = tokenizer.eos_token

```

Il modello generativo è stato impiegato per analizzare le risposte degli psicologi e assegnare **tre** possibili disturbi ad ognuna di esse. La logica del sistema si basa su un prompt strutturato in lingua inglese, definito in modo da istruire il modello a comportarsi come un **classificatore clinico rigoroso**. A ogni risposta dello psicologo, il modello riceve in input un messaggio che include l'elenco completo dei disturbi mentali, estratto dal DSM-5-TR, e produce in output tre diagnosi plausibili scelte esclusivamente da tale lista.

```

1 tqdm.pandas(desc="Classificando risposte")
2
3 # Classificazione
4 def classification(psychologist):
5     system = f"""
6     You are a strict mental health classifier.
7
8     You will be given a response written by a psychologist to a patient.
9
10    Your ONLY task is to infer exactly three possible mental health
11    disorders that the patient might be experiencing, based on that
12    response.
13
14    You must choose the disorders ONLY from the following list:
15    {mental_disorders_str}
16
17    Output ONLY the names of the three disorders, separated by commas,
18    on a single line.
19
20    Do NOT add any explanations, warnings, advice, or extra text. Do NOT
21    refer to the psychologist or the user. Just output the disorders.
22    """
23
24     chat = [{'role': 'system', 'content': f'{system}'},
25             {'role': 'user', 'content': f'{psychologist}'}]
26
27     try:
28         tokenized_chat = tokenizer.apply_chat_template(chat, tokenize=
29             True, add_generation_prompt=True, truncation=True, return_tensors="pt
30             ")
31         outputs = classification_model.generate(tokenized_chat.to(device
32             ), temperature=1, max_length=8192)
33         output_str = tokenizer.decode(outputs[0], skip_special_tokens=


```

```

True)
26     first_occurrence = output_str.find("GPT4 Correct Assistant:")
27     response = output_str[first_occurrence + len("GPT4 Correct
Assistant:"):].strip()
28
29     # Rimuovi eventuali ripetizioni di "GPT4 Correct Assistant:" all
'inizio della risposta
30     if response.startswith("GPT4 Correct Assistant:"):
31         response = response[len("GPT4 Correct Assistant:"):].strip()
32     except Exception as e:
33         response = 'No classification'
34         print(e)
35     return response
36
37 # Applica la classification su ogni riga della colonna Response
38 df['Disorders'] = tqdm(df['Response'].progress_apply(classification))
39
40 # Salvataggio del CSV
41 df.to_csv('/kaggle/working/output.csv', index=False)
42 print("File salvato in /kaggle/working/output.csv")

```

Successivamente alla classificazione automatica, i disturbi assegnati dal modello generativo sono stati elaborati per contare la frequenza con cui ciascun disturbo è stato assegnato. Per identificare in maniera visiva i disturbi più ricorrenti all'interno delle risposte analizzate è stato realizzato un grafico a barre con scala logaritmica sull'asse delle frequenze.



5 Generazione delle risposte pre-finetuning

In questa fase del progetto, è stato avviato un esperimento di generazione automatica di risposte psicologiche utilizzando modelli linguistici di tipo generativo. L'obiettivo è

quello di imitare lo stile comunicativo degli psicologi, facendo leva su tecniche di prompt engineering, senza effettuare un fine-tuning dei modelli.

Modelli considerati: Sono stati selezionati tre modelli preaddestrati con capacità istruttive:

- **LLaMA 3.2B Instruct:** La collezione Llama 3.2 è costituita da modelli di linguaggio di grandi dimensioni (LLM) multilingue, disponibili nelle versioni da 1B e 3B, ottimizzati per il dialogo, il recupero di informazioni e la sintesi testuale. Si tratta di modelli generativi auto-regressivi basati su un'architettura transformer ottimizzata. Le versioni istruite utilizzano fine-tuning supervisionato (SFT) e reinforcement learning con feedback umano (RLHF) per garantire risposte utili e sicure [7].
- **Qwen2.5-3B Instruct:** La collezione Qwen2.5 è una serie di modelli di linguaggio di grandi dimensioni che include sia modelli base sia modelli ottimizzati con istruzioni, con dimensioni che vanno da 0,5 a 72 miliardi di parametri. Questi modelli hanno una conoscenza molto ampia e sono particolarmente efficaci nella programmazione e nella matematica. Sono in grado di seguire istruzioni complesse, generare testi molto lunghi, comprendere dati strutturati come tabelle e produrre output strutturati, ad esempio in formato JSON. Supportano contesti molto estesi fino a 128.000 token e possono generare testi di circa 8.000 token. Inoltre, Qwen2.5 è multilingue e gestisce più di 29 lingue, tra cui cinese, inglese, francese, spagnolo, portoghese, tedesco, italiano, russo, giapponese, coreano, vietnamita, thailandese e arabo [9].
- **Gemma 3 4B IT:** Gemma 3 è una famiglia di modelli leggeri e avanzati sviluppati da Google, in grado di elaborare testo e immagini e generare testo in uscita. Supporta contesti molto estesi (fino a 128.000 token) e oltre 140 lingue. È adatto a compiti come rispondere a domande, riassumere testi e analizzare immagini. Grazie alle dimensioni ridotte, può essere eseguito anche su computer portatili, desktop o cloud personali, rendendo l'IA avanzata accessibile a tutti. Gli input possono essere testo o immagini, e l'output consiste in testo generato fino a 8.192 token [6].

```
1 models = ['meta-llama/Llama-3.2-3B-Instruct',
2           'Qwen/Qwen2.5-3B-Instruct',
3           'google/gemma-3-4b-it']
4
5 def set_model(model_name):
6     tokenizer = AutoTokenizer.from_pretrained(model_name)
7
8     if model_name != 'google/gemma-3-4b-it':
9         model = AutoModelForCausalLM.from_pretrained(model_name)
10        device = torch.device("cuda" if torch.cuda.is_available() else "
cpu")
11        model = model.to(device)
12
13        if tokenizer.pad_token is None:
14            print("Tokenizer has no pad token.")
15            tokenizer.pad_token = tokenizer.eos_token
16    else:
17        torch_dtype = torch.bfloat16
```

```

18     model = AutoModelForCausalLM.from_pretrained("google/gemma-3-4b-
    it", device_map="auto", torch_dtype=torch_dtype, attn_implementation="
    eager")
19     return tokenizer, model

1 tokenizer_meta, model_meta = set_model(models[0])
2 tokenizer_qwen, model_qwen = set_model(models[1])
3 tokenizer_gemma3, model_gemma3 = set_model(models[2])
4 pipe = pipeline("text-generation", model=model_gemma3, tokenizer=
    tokenizer_gemma3)
5 stop_token_ids = [tokenizer_gemma3.eos_token_id, tokenizer_gemma3.
    convert_tokens_to_ids("<end_of_turn>")]

```

Dataset: Per la fase di generazione delle risposte, è stato considerato un sottoinsieme del dataset contenente una sola occorrenza per ciascuna domanda nel dataset. Successivamente, questo sottoinsieme è stato suddiviso in due porzioni: un set di addestramento e un set di test, con una proporzione del 70% per il training e del 30% per il test. In questa fase di generazione di risposte senza finetuning si considera soltanto il test set.

```

1 unique_questions_df = df.drop_duplicates(subset='Context')
2 train_df, test_df = train_test_split(unique_questions_df, test_size=0.3,
    random_state=42)

```

Prompts considerati: Per controllare lo stile e il tono delle risposte generate dai modelli, è stata definita una funzione *get_chat* che costruisce un prompt strutturato nel formato di chat compatibile con i modelli generativi. La funzione consente di configurare il messaggio del system, ovvero le istruzioni comportamentali date al modello. I prompt considerati sono:

1. **Prompt Neutro:** Non include nessuna istruzione nel messaggio di sistema. Il modello riceve solo la domanda del paziente. L'obiettivo è osservare la risposta spontanea del modello senza vincoli comportamentali.
2. **Prompt generico:** Il messaggio di sistema indica che il modello deve comportarsi come uno psicologo, rispondendo con empatia in un paragrafo. In questo caso si cerca di guidare il modello verso uno stile professionale ed empatico, senza riferimenti a disturbi specifici.
3. **Prompt specializzato:** Il messaggio di sistema include l'indicazione del disturbo mentale da considerare, chiedendo al modello di rispondere in modo empatico e mirato. Qui si prova a simulare una risposta consapevole del contesto clinico, coerente con l'ipotetica diagnosi del paziente trovata durante la classificazione.

```

1 def get_chat(user, system=None, disorder=None):
2     chat = []
3     if system:
4         if disorder:
5             system = f"""Given the patient's situation and the
    identified mental health disorder ({disorder}), respond
    empathetically as a professional psychologist. Your response should
    acknowledge the patient's feelings and offer supportive and
    understanding guidance, without directly naming the disorder. Focus
    on providing emotional support and suggesting practical steps for
    improvement."""
6         else:

```

```

7         system = """Act like a professional psychologist. You must
respond empathetically and professionally in one paragraph without
items."""
8         chat.append({"role": "system", "content": system})
9         chat.append({"role": "user", "content": user})
10        return chat

```

Per la generazione delle risposte è stata definita una funzione dedicata, *generate_response* per costruire le risposte testuali a partire dai contesti delle conversazioni. A seconda del modello utilizzato, è stata applicata una logica di generazione differenziata:

- Per modelli compatibili Qwen e LLama, la generazione è stata effettuata mediante il metodo *.generate()* con parametri configurati per favorire la diversità e la coerenza della risposta, ovvero temperatura=0.85, top_k=64, top_p=0.93, penalità per la ripetizione, e sampling attivato.
- Per il modello Gemma3, è stata utilizzata una pipeline preconfigurata con una gestione specifica dell'input e della terminazione del testo (mediante *eos_token_id*) e gli stessi valori di temperatura, top_k e top_p.

I testi generati sono stati memorizzati in nuove colonne all'interno del DataFrame, con un nome che indica il modello e il tipo di prompt utilizzato tramite *apply_with_progress()*.

```

1  tqdm.pandas(desc="Generando risposte")
2
3  def generate_response(row, model, tokenizer, model_name, prompt='
neutrale'):
4      if prompt == 'neutrale':
5          chat = get_chat(row['Context'])
6      elif prompt == 'generico':
7          chat = get_chat(row['Context'], system=True)
8      elif prompt == 'specializzato':
9          chat = get_chat(user=row['Context'], system=True, disorder=row['
Disorders'])
10
11     if model_name != 'gemma3':
12         prompt = tokenizer.apply_chat_template(chat, tokenize=True,
add_generation_prompt=True, return_tensors="pt").to(device)
13         outputs = model.generate(prompt.to(device),
14                                 max_new_tokens=256,
15                                 pad_token_id=tokenizer.pad_token_id,
16                                 temperature=0.85,
17                                 top_k=64,
18                                 top_p=0.93,
19                                 repetition=1,
20                                 do_sample=True)
21
22         answer = tokenizer.decode(outputs[0], skip_special_tokens=True)
23         answer = answer.split("assistant\n", 1)[1] if "assistant\n" in
answer else answer
24
25     else:
26         prompt = pipe.tokenizer.apply_chat_template(chat, tokenize=False
, add_generation_prompt=True)
27         output = pipe(prompt, max_new_tokens=256,
28                       do_sample=True, temperature=0.85,
29                       top_k=64, top_p=0.93,
30                       eos_token_id=stop_token_ids,

```

```

31         disable_compile=True)
32     answer = output[0]['generated_text'].split('model\n')[1]
33
34     return answer
35
36 def apply_with_progress(df, model, tokenizer, prompt, desc_msg, filename
, model_name):
37     print(desc_msg)
38     df[f'{model_name} {prompt}'] = df.progress_apply(
generate_response_row, axis=1,
39                                     args=(model,
tokenizer, model_name, prompt))
40     df.to_csv(f'/kaggle/working/{filename}', index=False)
41     print(f"Salvataggio completato: /kaggle/working/{filename}")
42     return df

```

5.1 Risposte generate

A modo di esempio si mostrano a continuazione una domanda e risposta del dataset e le risposte generate da ogni modello per ogni prompt considerato.

- **Domanda paziente:** *I don't remember when the voices in my head started, but I remember Hearing them when I was little. I know it's not normal to hear voices that aren't your own. I fight the voices and I want them to stop. They've been here so long and I want them gone. How can I make the voices stop?*
- **Risposta psicologo:** *This isn't something you can do on your own. If you haven't already, you need to see a medical doctor ASAP to rule out medical causes for this. Many diseases, illnesses, and conditions can cause hallucinations. In the elderly, sometimes it's something as simple as a urinary tract infection. Some medicines may have that side effect as well. However, you say you've been hearing them since you were little. I have no idea how old you are now, but something that has been going on for many years does lead me to think it could be a type of schizophrenia. A psychiatrist could diagnose that after taking a complete look at your history, medical history, etc. There are medications that they can put you on that will help. One thing that I find encouraging is that you recognize you're hearing voices. This means you are not so far into a delusion as to believe it is real. A lot of people that hear or see things that aren't there are not able to have the awareness that these things are not real. They fully believe what they're hearing/seeing. It's completely real to them. Because you have the awareness that you do, I feel this is a very good sign that with treatment you can live a normal life (assuming you are not already receiving treatment for it. If you are and are still hearing the voices, please know that medications often need to be changed and adjusted, and the voices may never completely go away but medicines certainly help dull them a lot. Always talk to your doctor when it seems your symptoms are getting worse so that they can make the necessary medication adjustments for you).If at any time the voices are telling you to do something, please go to an ER as this is an emergency. Sometimes people hear voices telling them to harm themselves, harm someone else, or do other things that are against the law. Do not try to deal with something like that on your own. There are people who can help.*
- **Disturbi trovati:** *Hallucinogen Use Disorder, Schizophrenia, Toxic Psychosis*

5.1.1 Generazione risposte Qwen

- **Con prompt Neutrale:** *I'm sorry to hear about the challenges you're facing. It's important to acknowledge that experiencing voices can be very distressing and can significantly impact your well-being. Here are some steps you might consider taking:1. ****Seek Professional Help****: It's crucial to consult a mental health professional such as a psychologist, psychiatrist, or a counselor who specializes in conditions like psychosis or hearing voices (auditory hallucinations). They can provide a proper evaluation and treatment plan tailored to your specific situation.2. ****Cognitive Behavioral Therapy (CBT)****: CBT is a common treatment for conditions involving hallucinations. It helps you understand and change unhelpful patterns of thinking and behavior.3. ****Medication****: Depending on the severity and cause of your auditory hallucinations, your doctor might recommend medication. Antipsychotic drugs are often used in cases of hallucinations and delusions.4. ****Support Groups****: Joining a support group can be beneficial. You can connect with others who are going through similar experiences, which can provide comfort and valuable advice.5. ****Mindfulness and Relaxation Techniques****: Practices such as mindfulness, meditation, and deep breathing can help manage symptoms and reduce stress.6. ****Healthy Lifestyle****: Maintaining a healthy lifestyle can also contribute to*
- **Con prompt Generico:** *I understand how challenging it must be to deal with persistent voices that feel so real to you. It's reassuring that you are recognizing the voices as a concern and taking steps to address them. It's important to approach this with patience and care. Cognitive-behavioral therapy is often effective in helping individuals manage intrusive thoughts and voices. Working with a psychologist who specializes in such conditions can provide you with tailored strategies to cope and potentially reduce their impact. Additionally, mindfulness practices and grounding techniques might help you manage the intensity of these voices. Remember, it's a gradual process, and acknowledging your feelings and seeking support are significant steps towards finding relief.*
- **Con prompt Specializzato:** *I understand how you feel. The voices in your mind can be very challenging, and it's understandable that you want them to go away. It's good that you are taking steps to address this, as recognizing your struggle is a strong first step. Here are some strategies that might help:1. ****Seek Professional Help****: It's important to work with a mental health professional who can provide support and explore various treatment options such as therapy or medication. They can help you understand the voices and develop strategies to manage them.2. ****Consistent Routine****: Keeping a regular daily routine can provide structure and a sense of normalcy, which can be comforting. Try to include activities that you enjoy or that help you relax.3. ****Mindfulness and Relaxation Techniques****: Practices like meditation, deep breathing exercises, or yoga can help you feel more centered and less overwhelmed by the voices.4. ****Journaling****: Writing down your thoughts and feelings can help you sort through your experiences and might make the voices feel less overwhelming. It can also be a place to explore your feelings and thoughts more deeply.5. ****Support from Loved Ones****: Talking to people you trust can provide emotional support and help you feel less isolated. Even if they don't understand the voices, your loved ones*

5.1.2 Generazione risposte Meta-LLama

- **Con prompt Neutrale:** *I'm so sorry to hear that you're experiencing this. Hearing voices that aren't your own can be a distressing and isolating experience. While it's understandable that you want the voices to stop, it's essential to approach this situation with compassion and seek professional help. Here are some steps you can take:1. ****Seek professional help****: Consult a mental health professional, such as a psychologist, psychiatrist, or therapist, who specializes in hearing voices or auditory hallucinations. They can help you understand the underlying causes of your experiences and develop strategies to manage them.2. ****Keep a journal****: Keeping a record of when the voices occur, what they say, and how you respond can help you identify patterns and triggers. This information can be invaluable for your therapist to understand your experiences.3. ****Practice self-care****: Engage in activities that bring you comfort, relaxation, and joy, such as exercise, meditation, or creative pursuits. This can help reduce stress and anxiety, which may contribute to the voices.4. ****Learn coping skills****: Your therapist can teach you techniques to manage your emotions and reduce the impact of the voices. These may include mindfulness, deep breathing, or cognitive-behavioral therapy (CBT) skills.5. ****Consider medication***
- **Con prompt Generico:** *I can sense the distress and frustration you're experiencing, and I want to assure you that I'm here to listen and support you. Hearing voices that aren't your own, especially since childhood, can be a challenging and isolating experience. It takes immense courage to acknowledge and share this with someone. While there's no guaranteed "cure" for voices, I want to emphasize that making them stop may not be possible, but we can work together to develop strategies to manage and cope with them. We can explore cognitive-behavioral techniques, grounding exercises, and relaxation methods to help you regain control and reduce their frequency. It's also essential to address any underlying emotional or psychological issues that may be contributing to the voices. With a non-judgmental and compassionate approach, I'm here to support you in finding ways to coexist with the voices and improve your overall well-being.*
- **Con prompt Specializzato:** *I'm so sorry to hear that you're experiencing this. It sounds like it's been a really difficult and isolating experience for you. First of all, I want you to know that you're not alone, and I'm here to support you. It's completely understandable that you're feeling overwhelmed and frustrated with these voices. It's like they're constant companions, and it's hard to shake the feeling that you're losing control. Before we talk about making the voices stop, I want to acknowledge that this is a really tough spot to be in. It's not uncommon for people to feel like they're stuck in this cycle, and it's okay to feel that way. You're not a burden, and you don't have to go through this alone. One thing that might help is to focus on self-care. What are some things that you enjoy doing that help you feel grounded and centered? Are there any activities that you find calming or relaxing? When you engage in these activities, do you feel like the voices are quieter or less intrusive? Also, I want to talk about the idea of "fighting" the voices. While it's understandable that you might want to try to push them away, research has shown that this can sometimes make things worse. Instead*

5.1.3 Generazione risposte Gemma3

- **Con prompt Neutrale:** *Okay, it takes a lot of courage to even talk about this, and I want to acknowledge that you've already taken a huge step just by reaching out and sharing this with me. It's completely understandable that you're feeling distressed and wanting the voices to stop – they're clearly impacting your life, and it's valid to want relief. Let's address this with care and a focus on getting you support.**First, let's be clear: Hearing voices is a complex experience, and it's not something you're alone in experiencing.** Many people do, and it doesn't automatically mean something is "wrong" with you. It can be a symptom of various underlying factors, and there are many ways to manage and cope with them.**Here's a breakdown of what's going on and what you can do, broken down into immediate steps, understanding what might be happening, and long-term strategies:***1. Immediate Steps - What You Can Do Right Now:*** **Grounding Techniques:** When the voices are particularly strong, grounding techniques can help bring you back to the present moment. Here are a few: * **5-4-3-2-1 Technique:***
- **Con prompt Generico:** *It sounds incredibly distressing to be experiencing these persistent voices and to feel like they're significantly impacting your life. It takes immense courage to acknowledge this and reach out for support, and I want to validate the intensity of what you're going through – it's completely understandable why you'd want them to stop and feel like this is a significant challenge. Recognizing that this isn't "normal" can be a difficult experience, but it's important to remember that you're not alone and there are effective strategies and professional guidance available to help you navigate these internal experiences and develop coping mechanisms to regain a sense of control and peace.*
- **Con prompt Specializzato:** *Okay, thank you for sharing this with me. It takes a lot of courage to talk about something so deeply personal and unsettling, and I want to acknowledge how incredibly difficult it must be to experience these voices. It sounds like you've been grappling with this for a very long time, and it's completely understandable that you want them to stop and that you're feeling frustrated and exhausted by the effort of trying to quiet them. It's really brave of you to recognize that this isn't typical, and that you're actively fighting against them. That shows a huge amount of strength and a desire to reclaim your experience. It's completely valid to feel overwhelmed when something like this is constantly present in your thoughts – it's like carrying a heavy weight, and it's okay to admit you're struggling. I hear you saying you want them gone, and I want you to know that I'm here to support you in finding ways to lessen their impact on your life. There isn't a simple "switch" to turn them off, and it's not about trying to force them away, because that often just makes them stronger. Right now, let's focus on finding some ways*

L'analisi delle risposte generate ha evidenziato che tutti i modelli sono stati in grado di produrre output coerenti, empatici e tendenzialmente utili. Tuttavia, si è riscontrata una differenza sistematica nel tipo di contenuto generato in base al prompt utilizzato. In particolare, il **prompt neutrale** ha prodotto risposte molto strutturate sotto forma di elenco di consigli pratici (es. terapia, farmaci, gruppi di supporto), ma spesso ha mantenuto una certa distanza clinica, suggerendo quasi sempre di rivolgersi a uno specialista. Questo lo rende meno credibile come sostituto di un vero psicologo, apparendo più come

un mediatore informativo. Al contrario, i **prompt generici** e **specializzati** hanno generato risposte più fluide, colloquiali e personalizzate, mostrando maggiore empatia e una relazione di ascolto più realistica. In generale, l'uso di prompt specializzati si è rivelato efficace nel migliorare la pertinenza e la qualità delle risposte, soprattutto in contesti psicologici complessi.

5.2 Valutazione delle risposte generate

Per valutare la qualità delle risposte generate dai modelli sono state utilizzate quattro metriche automatiche. Ogni metrica misura in modo differente la somiglianza tra la risposta generata e la risposta originale dello psicologo presente nel dataset.

- **Cosine Similarity (TF-IDF)**: Misura la vicinanza tra testi confrontando i vettori di termini pesati con TF-IDF; più è alto il valore, più i testi condividono contenuto lessicale.
- **BERTScore**: Valuta la similarità semantica tra frasi usando embedding contestuali di BERT; cattura sinonimi e parafrasi meglio delle metriche basate su n-grammi.
- **METEOR**: Confronta n-grammi, radici e sinonimi tra ipotesi e riferimento, bilanciando precisione e recall lessicale.
- **BLEURT**: Metrica di apprendimento supervisionato che stima la qualità di un testo rispetto a un riferimento usando un modello BERT fine-tunato su giudizi umani. Un valore BLEURT negativo indica che il testo generato è peggiore della media rispetto al riferimento umano.


```
1 bertscore = evaluate.load("bertscore")
2 bleurt = evaluate.load("bleurt")
3
4 def get_similarity(reference, generated):
5     vectorizer = TfidfVectorizer()
6     tfidf = vectorizer.fit_transform([generated, reference])
7     return cosine_similarity(tfidf[0:1], tfidf[1:2])[0][0]
8
9 def get_bertscore(reference, generated):
10    score = bertscore.compute(predictions=[generated], references=[
11    reference], lang="en")
12    return score['f1'][0]
13
14 def get_bleurt(reference, generated):
15    score = bleurt.compute(predictions=[generated], references=[
16    reference])
17    return score['scores'][0]
18
19 def get_meteor(reference, generated):
20    return meteor_score([word_tokenize(reference)], word_tokenize(
21    generated))
22
23 def evaluate_metrics(row, model_name):
24    prompts = ['neutrale', 'generico', 'specializzato']
25    result = {}
26
27    reference = row['Response']
28    for prompt in prompts:
```

```

7     generated = row[f'{model_name} {prompt}']
8
9     # Similarity
10    sim = get_similarity(reference, generated)
11    result[f'similarity {prompt}'] = sim
12
13    # Bertscore
14    bertscore = get_bertscore(reference, generated)
15    result[f'bertscore {prompt}'] = bertscore
16
17    # Bleurt
18    bleurt = get_bleurt(reference, generated)
19    result[f'bleurt {prompt}'] = bleurt
20
21    # Meteor
22    meteor = get_meteor(reference, generated)
23    result[f'meteor {prompt}'] = meteor
24
25    return result

```


Per ciascuna combinazione di metrica e prompt, è stato calcolato il valore medio della metrica corrispondente per confrontare visivamente le performance delle risposte generate da un modello in base al tipo di prompt utilizzato. Di seguito vengono riportati i risultati ottenuti.



Dall'analisi del grafico emerge che le metriche calcolate sul modello **Qwen** hanno valori piuttosto simili tra i tre tipi di prompt. Questo indica che la sensibilità del modello alla variazione del prompt è bassa e i benefici del cambiamento sono limitati.


- **Similarity:** Si ottengono valori abbastanza vicini, anche se il prompt **specializzato** ha la similarità più alta, quindi produce risposte più vicine al riferimento.

- **BERTScore**: Qui i valori sono praticamente uguali. Questo dice che il modello mantiene una qualità di matching semantico quasi identica indipendentemente dal prompt.
- **METEOR**: Anche qui i valori sono vicini, ma il **generico** tende a essere un po' più basso e quindi meno allineato a livello di lessico.
- **BLEURT**: I valori sono tutti negativi (segno che BLEURT valuta le risposte come non troppo vicine a testi umani di riferimento). Anche qui però le differenze sono minime, con il generico leggermente meglio.



Il modello Meta LLama sembra poco sensibile alla variazione del prompt, e mantiene prestazioni stabili su tutte le metriche.

- **Similarity**: Il prompt specializzato si distingue con il valore più alto, mentre neutrale e generico sono molto vicini tra loro ma più bassi.
- **BERTScore**: Qui domina il generico, seguito da vicino dallo specializzato. Il neutrale è leggermente inferiore.
- **METEOR**: Il prompt specializzato ha il valore migliore, seguito dal neutrale. Il generico è più basso.
- **BLEURT**: Il generico ha il valore meno negativo (quindi migliore). Lo specializzato è a metà, mentre il neutrale è il peggiore.



Nel complesso, Gemma3 sembra più sensibile al tipo di prompt, con oscillazioni più evidenti nelle metriche, anche se nessuna categoria prevale nettamente su tutte.

- **Similarity:** Il prompt **specializzato** ha la similarità più alta, seguito dal **neutrale**. Il **generico** è più basso, quindi produce testi leggermente meno vicini ai riferimenti.
- **BERTScore:** Qui domina il **generico**, con uno scarto piccolo ma positivo. Il **neutrale** è più basso, mentre lo **specializzato** si posiziona a metà.
- **METEOR:** Come in similarity, lo **specializzato** ottiene il punteggio migliore, seguito dal **neutrale**. Il **generico** resta indietro.
- **BLEURT:** Tutti i valori sono negativi, ma il **generico** ha il punteggio meno negativo (quindi migliore). Lo **specializzato** invece ha il più basso (-0.784), segnalando un peggioramento rispetto agli altri.

6 Finetuning Modelli

Per la fase di training dei modelli è stata seguita la seguente metodologia.

Tipo dei dati: Il tipo di dato scelto per i calcoli è `bfloat16`, una rappresentazione numerica più efficiente della tradizionale `float32`, che consente di risparmiare memoria e velocizzare l'addestramento, pur mantenendo un buon livello di precisione.

Tecnica di finetuning: L'allenamento dei modelli è stato fatto tramite **QLoRA** (Quantized Low-Rank Adaptation) [3]. Questa è una tecnica che permette di fare fine-tuning efficiente di modelli linguistici di grandi dimensioni riducendo costi e memoria. Funziona quantizzando i pesi del modello in 4 bit per ridurre l'uso di GPU e applicando sopra di essi LoRA, ovvero una tecnica di fine-tuning che non aggiorna tutti i pesi di un modello, ma aggiunge piccole matrici a rango ridotto all'interno dei layer già esistenti. Durante l'addestramento, i pesi originali restano congelati e solo queste matrici leggere vengono ottimizzate, riducendo drasticamente il numero di parametri da aggiornare e la memoria necessaria. In questo modo si può adattare rapidamente un modello molto grande a nuovi task con costi computazionali contenuti.

La configurazione viene gestita attraverso la classe **BitsAndBytesConfig**, che specifica che il modello deve essere caricato in 4 bit utilizzando la quantizzazione `nf4`, la quale è stata dimostrata essere più stabile e performante rispetto ad altre tecniche. Inoltre, viene attivata la doppia quantizzazione, un metodo che riduce ulteriormente lo spazio occupato dai pesi mantenendo la qualità del modello.

```
1 torch_dtype = torch.bfloat16
2
3 # QLoRA config
4 bnb_config = BitsAndBytesConfig(
5     load_in_4bit=True,
6     bnb_4bit_quant_type="nf4",
7     bnb_4bit_compute_dtype=torch_dtype,
8     bnb_4bit_use_double_quant=True,
9 )
10
11 model_kwargs = dict(
12     attn_implementation='eager',
13     torch_dtype=torch_dtype,
14     device_map="balanced",
15     quantization_config=bnb_config
16 )
```

Una volta definita la configurazione, il modello viene effettivamente caricato attraverso la funzione `from_pretrained`, che richiama il modello da **Hugging Face Hub** e applica tutte le specifiche appena definite. Allo stesso tempo, anche il tokenizer viene caricato.

```
1 model = AutoModelForCausalLM.from_pretrained(model_id, **model_kwargs)
2 tokenizer = AutoTokenizer.from_pretrained(model_id, device_map='balanced',)
```

Preparazione del dataset: Dopo aver caricato i dati, si estrae l'insieme delle domande uniche (definite dalla colonna **Context**), con l'intento di usarli come base per la suddivisione del dataset di **training** e di **test** con un rapporto 75/25. Questo approccio consente di evitare che frasi simili compaiano in entrambi i set, riducendo il rischio di **data leak**.

age: una situazione in cui informazioni non disponibili al momento dell'addestramento del modello vengono incluse nel dataset. Questo fenomeno porta a una sovrastima delle performance durante la validazione, ma a prestazioni significativamente peggiori su dati reali o non visti.

Configurazione PEFT (Parameter-Efficient Fine-Tuning): Utilizzando la tecnica LoRA (Low-Rank Adaptation), la configurazione prevede:

- `r=64`, valore che indica la dimensione del rango ridotto,
- `lora_alpha=16`, che modula l'intensità dell'adattamento,
- `lora_dropout=0.05`, utile a ridurre l'overfitting.

I layer target sono tutti quelli lineari (`target_modules="all-linear"`), e si salvano anche i layer di embedding e l'output finale (`lm_head`). Questo approccio consente di mantenere bassi i costi computazionali, specialmente quando si lavora con modelli di grandi dimensioni.

Configurazione dell'addestramento: Viene gestita attraverso **SFTConfig**, una classe fornita dalla libreria **trl** (Transformers Reinforcement Learning). Qui si definiscono tutti gli iperparametri necessari:


- Lunghezza massima delle sequenze fissata a 256 token.
- `packing` abilitato che consente di ottimizzare l'uso del batch combinando più input brevi nella stessa sequenza di input.
- `batch_size` settata a 1 per dispositivo, ma con un'accumulazione dei gradienti ogni 8 passaggi, il che equivale a un **batch** effettivo di 8.
- `gradient_checkpointing` abilitato, che riduce l'uso di memoria sacrificando un po' di tempo computazionale,
- l'ottimizzatore scelto è `paged_adamw_32bit`, particolarmente adatto a lavorare con modelli quantizzati [3].
- `learning_rate` settato a $2e-4$, compensato dalla presenza di un **warmup** iniziale, che consente al modello di stabilizzarsi prima di iniziare il vero e proprio apprendimento.
- il tutto viene eseguito in **mixed-precision** con `bf16`.

Infine, viene istanziato l'oggetto **SFTTrainer**, che coordina il **training** supervisionato. Questo oggetto riceve il modello, la configurazione, il dataset e la configurazione **LoRA**, oltre al tokenizer che fungerà da preprocessore.

La durata degli addestramenti è impostata in maniera diversa in base al tipo di modello.

6.1 Modello Qwen 2.5

Con il modello **Qwen** è stato impostato il numero di epoche a 3:



Dal grafico si nota una curva irregolare che mostra un trend chiaramente **decescente**. All'inizio del **training**, la loss **alta** (>3.0), il che è normale: il modello non è ancora adattato ai dati specifici del dominio. Con il progredire delle epoche, la loss scende in maniera continua segno che il modello **sta apprendendo informazioni significative** dal dataset.

L'andamento presenta molte **oscillazioni** locali. Questo può derivare da diversi fattori:


- **Dati complessi o non omogenei**: i dati legati alla salute mentale possono essere molto variabili.
- **Batch Size ridotto**: ogni aggiornamento del modello è influenzato da piccoli campioni, il che introduce rumore.

Secondo [4], il tutto potrebbe essere causato da uno **shuffle** del dataset. In corrispondenza dei passaggi tra le epoche (circa a **1** e **2**) si nota un leggero salto di distribuzione.

Nella parte finale del training (tra **2.5** e **3** epoche), invece, la loss **si stabilizza attorno a valori tra 0.8 e 1.0**.


6.1.1 Metriche di Valutazione

Di seguito vengono riportate le metriche di valutazione del modello Qwen:

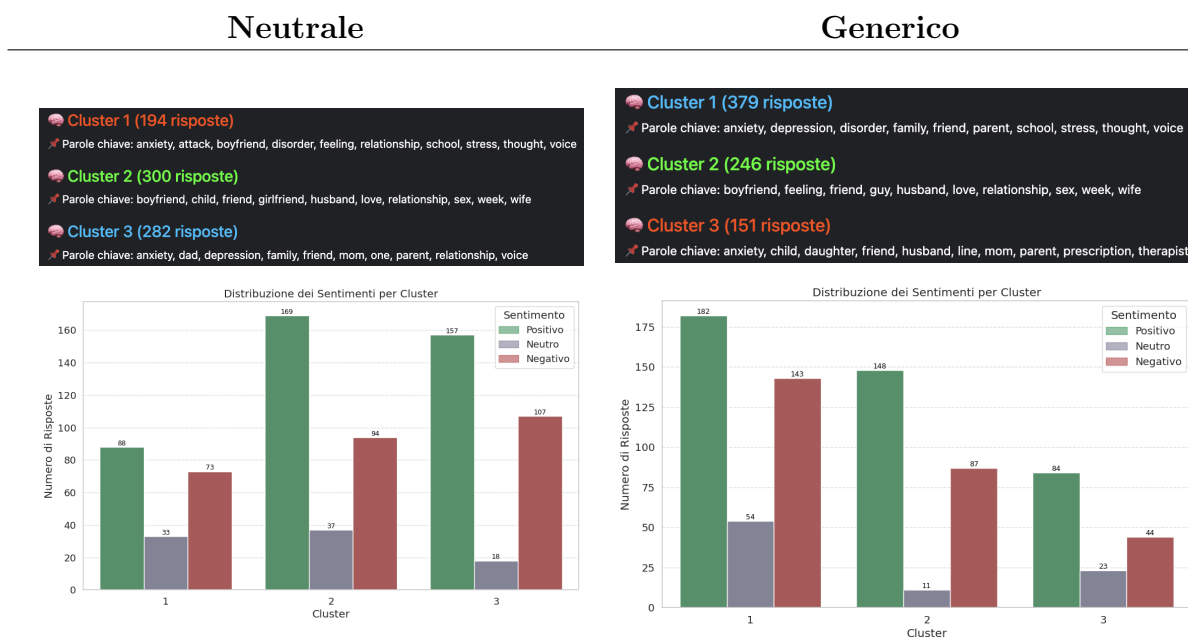


Dalle immagini non risultano notevoli miglioramenti dal punto di vista della generazione. Tuttavia questo si spiega poiché le risposte generate hanno un numero fissato di token da generare, mentre nel dataset le risposte reali possono essere di qualsiasi lunghezza. Da calcoli **Pre-FineTuning**, la lunghezza media delle risposte fornite dagli psicologi è intorno alle 172 parole. In media 172 parole possono essere suddivise tra i 220 e i 300 tokens. Di conseguenza si è scelto di far generare risposte per un **max** di 250 tokens.

Si procede a questo punto con il valutare l'**analisi del sentimento** nelle risposte generate dal modello **Qwen**.



Dal punto di vista visivo, si nota una separazione tra i cluster bene definita con tutti i prompt, principalmente in quello **Specializzato**. Nella tecnica **Neutrale**, i cluster sono discretamente separati, ma c'è una certa sovrapposizione tra rosso e verde. Indica che le risposte sono abbastanza variate, ma mantengono una certa coerenza nei temi trattati. Nella tecnica **Generica**, invece, c'è più sovrapposizione tra i cluster rispetto alla modalità **Neutrale**. Questo potrebbe suggerire che le risposte siano meno specifiche e più ambigue semanticamente, con un contenuto più vario ma meno coerente. Nella tecnica **Specializzata**, i cluster appaiono molto distinti, con chiara separazione tra i gruppi. Indica una maggiore coerenza semantica delle risposte: ogni cluster rappresenta un sotto-tema ben definito.



Specializzato



Descrizione della modalità *Neutrale*:

Nella maggior parte delle risposte usa un tono complessivamente **positivo**, ma con forti oscillazioni tra cluster. Ad esempio nel cluster 1 ha una forte negatività. Questo infatti prevale sulle poche risposte **neutre** fornite. Nel cluster 2, invece, prevale il numero di risposte positive fornite dal modello. Nel cluster 3 tratta temi familiari e relazioni più complesse e il numero di sentimenti positivi prevale su quelli negativi.

Descrizione della modalità *Generico*:

Si ha un tono più variegato ma con **scarso** uso del **sentimento neutro** soprattutto nel cluster 2. Questo porta ad avere una maggiore polarizzazione tra positivo e negativo. Nello specifico nel cluster 2 che riguarda la tematica delle relazioni sentimentali, si ha una forte differenza tra risposte positive e negative con solo 11 risposte neutre. Quindi ha una minore capacità di sfumature.


Descrizione della modalità *Specializzato*:

In generale la distribuzione dei sentimenti nelle risposte risulta essere più coerente. Se si considera il cluster 1, risulta essere molto **sfumato**: la presenza del sentimento neutro suggerisce una gestione più analitica, con attenzione alla complessità delle emozioni, questo in riferimento alle tematiche trattate. Tra le tre modalità, risulta essere quella che separa meglio le tematiche trattate.

Da ciò quindi si può ricavare un comportamento pressoché uguale del modello nelle diverse modalità.

6.2 Modello Llama 3.2

Con il modello **Llama** è stato impostato il numero di epoche a 5:




L'andamento anche in questo caso sembra essere decrescente: la loss decresce progressivamente lungo le epoche, indicando che il modello sta apprendendo dalle informazioni fornite nel dataset. La curva, pur essendo rumorosa, mostra un chiaro miglioramento nel tempo, con una diminuzione della varianza e dei picchi.

La loss iniziale parte da un valore intorno a **3**, con picchi che raggiungono anche valori leggermente superiori a **4**. Mentre la loss finale sembra oscillare intorno a valori compresi tra **0.8** e **1.2**.

Le **oscillazioni** della loss sono molto marcate all'inizio, con picchi frequenti e instabilità. Con il procedere del training, le oscillazioni si attenuano gradualmente, ma non scompaiono del tutto.

6.2.1 Metriche di Valutazione

Di seguito vengono riportate le metriche di valutazione del modello Llama 3.2:






Dai risultati non si rilevano particolari differenze con il modello pre-finetuned. Di conseguenza si procede andando a considerare la **sentiment analysis** del modello per comprendere meglio il suo comportamento nella generazione del testo confrontando anche le diverse *tecniche di generazione*.

Neutrale

Generico

Specializzato




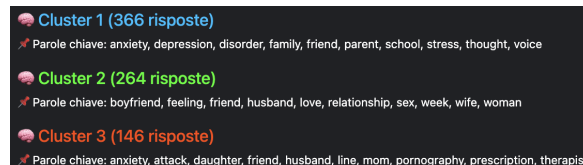
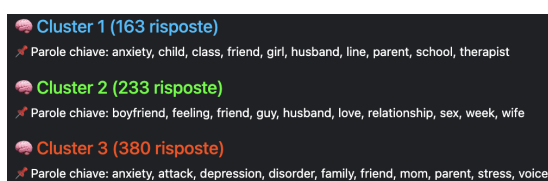
Da una prima analisi sono stati osservati anche nelle risposte 3 aspetti principali, che come già accennato in precedenza sono:

- Aspetti relativi a rapporti sentimentali.
- Aspetti familiari e generazionali.
- Aspetti psicologici e di benessere mentale.

Dal punto di vista visivo, si può già notare una buona separazione tra i cluster nelle risposte fornite dal modello **Neutrale** e **Generico**. In quello **Specializzato**, invece, le risposte sembrano più *complesse* e semanticamente vicine tra loro, con minore distinzione netta tra i cluster. Questo potrebbe riflettere un uso più ricco e variegato del linguaggio, che rende i confini tra gli argomenti meno netti.


Neutrale

Generico



Specializzato

Cluster 1 (228 risposte)
Parole chiave: anxiety, attack, family, feeling, forever, friend, personality, relationship, school, thought
Cluster 2 (261 risposte)
Parole chiave: boyfriend, child, friend, husband, love, mom, relationship, sex, week, wife
Cluster 3 (287 risposte)
Parole chiave: anxiety, binge, depression, disorder, family, friend, night, relationship, stress, voice



Descrizione della modalità *Neutrale*:

Dal conteggio delle risposte si nota una generazione incentrata principalmente su aspetti legati al benessere mentale e psicologico. Dal punto di vista invece *emotivo*, il modello tende ad avere un carattere diverso. Il cluster 2 ha la più alta proporzione di risposte **positive**, coerente con le parole chiave affettive e relazionali. Il cluster 3 mostra un forte squilibrio verso risposte negative, in linea con i temi di depressione, ansia e stress. Mentre il cluster 1 è più bilanciato nei sentimenti.

Descrizione della modalità *Generico*:

In questo caso prevale un approccio **emotivo forte**, raramente neutro. Le risposte sono spesso **ottimistiche** anche su temi problematici, ma senza profondità o cautela. Il cluster 1, nonostante tratti depressione e disturbi, ha quasi la stessa quantità di sentimenti positivi e negativi. Ciò suggerisce che il modello genera risposte *generiche* ma **ottimistiche per default**, anche in casi non appropriati. Il cluster 2 dimostra che il linguaggio utilizzato è principalmente positivo, ma anche suscettibile a oscillazioni. Il cluster 3 include temi **marginali** o **controversi**, gestiti con una certa prudenza.


Descrizione della modalità *Specializzato*:

In nessun cluster lo stile risulta essere polarizzato: anche nei contesti negativi, le risposte tendono ad avere un equilibrio tra **rassicurazione**, **realismo** e **supporto**. Il cluster 3 ha la percentuale più alta di risposte **neutre** rispetto agli altri stili. A differenza dello stile **generico**, qui le risposte sembrano **modulare il tono** in base alla gravità e alla delicatezza del tema. Anche nel cluster 2 i temi non sono trattati con semplicità. Tra le tre modalità, è quella che mostra la minore differenziazione tematica, adottando un approccio omogeneo a prescindere dal contenuto.

Da questo si può affermare che il modello nella modalità **Specializzata** si comporta peggio rispetto alle altre due, che approssimativamente trattano le tematiche allo stesso modo.

6.3 Modello Gemma3

Con il modello **Gemma3** è stato impostato il numero di epoche a 5:




Il grafico mostra un **trend decrescente** della loss nel corso delle epoche. La loss inizia attorno a valori di 30 e si riduce progressivamente fino a stabilizzarsi intorno a 5. Nella **prima epoca**, la loss presenta alta volatilità con valori iniziali molto elevati, seguiti da una rapida discesa. Questa è la fase di **apprendimento più dinamica** dove il modello si adatta rapidamente ai nuovi dati.

Nella **seconda epoca**, continua la tendenza decrescente. Nella **terza e quarta epoca** il trend discendente rallenta e la variabilità aumenta temporaneamente. La loss si stabilizza successivamente su valori più bassi (intorno a 5).

Aspetto particolare lo si nota nel passaggio tra la **seconda** e la **terza** epoca, con i valori della loss che tendono ad aumentare per poi riscendere nuovamente.

6.3.1 Metriche di Valutazione

Di seguito vengono riportate le metriche di valutazione del modello Gemma3:




I risultati non evidenziano differenze significative rispetto al modello pre-finetuned. Pertanto, si passa ad analizzare la **sentiment analysis** del modello al fine di comprendere più a fondo il suo comportamento nella generazione del testo, mettendo inoltre a confronto le varie *tecniche di generazione*.

Neutrale

Generico

Specializzato


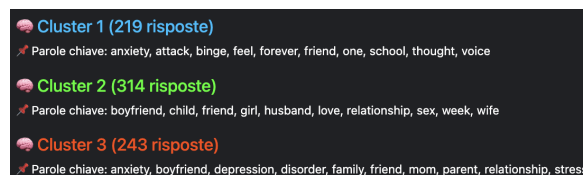

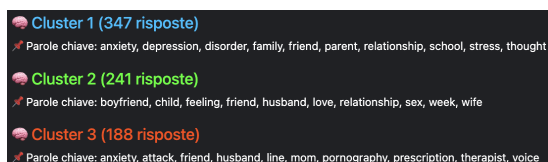


Analizzando i tre grafici del clustering si può notare che:


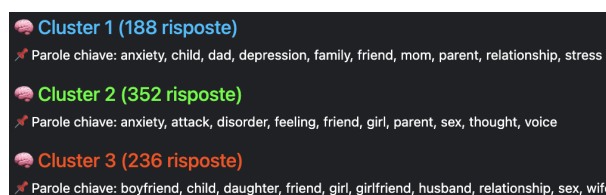
- **Neutrale:** i cluster mostrano una separazione moderata ma con alcune zone di sovrapposizione, specialmente tra il cluster 3 e il cluster 2. Il cluster 1 invece appare più compatto e distinto, suggerendo un tipo di risposta semanticamente più coerente.
- **Generico:** la separazione tra cluster è migliorata rispetto alla condizione neutrale. Il cluster 1 forma una nuvola più densa nella parte sinistra, mentre i cluster 3 e 2 occupano rispettivamente le zone centrali e destre dello spazio *PCA*.
- **Specializzato:** mostra la **separazione più netta** tra i cluster. Ogni gruppo occupa regioni distinte dello spazio semantico. Questa è la configurazione più *pulita* dal punto di vista del clustering, con cluster ben definiti e minimal overlap.

Neutrale

Generico



Specializzato



Descrizione della modalità *Neutrale*:

In questo caso, i cluster mostrano una distribuzione **relativamente bilanciata** con temi che si sovrappongono parzialmente. Le **parole chiave** evidenziano argomenti psicologici e relazionali distribuiti tra tutti i cluster. Tuttavia mostrano **sovrapposizione semantica significativa** tra cluster. Termini come *anxiety*, *depression*, *friend*, *relationship* appaiono in più cluster, indicando confini tematici sfocati. Il cluster 1 ha forte predominanza **positiva**, mentre cluster 2 e 3 sono più bilanciati.

Descrizione della modalità *Generico*:

Si osserva una redistribuzione con il cluster 2 che diventa dominante e una specializzazione tematica più marcata. Il cluster 1 si concentra su **temi emotivi negativi**, il cluster 2 su **relazioni interpersonali**, e il cluster 3 mantiene focus su **stress** e **disturbi**. Il cluster 2 mantiene alta positività, ma si nota un aumento relativo dei sentimenti negativi nei cluster 1 e 3.

Descrizione della modalità *Specializzato*:

La redistribuzione è ancora più pronunciata con il cluster 2 che raggiunge 352 risposte. I cluster mostrano una **specializzazione tematica molto più netta**: cluster 1 per dinamiche familiari e stress, cluster 2 per disturbi e sentimenti, cluster 3 per relazioni romantiche e interpersonali. Presenta il pattern più interessante con il cluster 2 che conserva alta positività ma con maggiore presenza di **sentimenti negativi** rispetto alle versioni precedenti. Questo suggerisce una maggiore capacità di gestire **sfumature emotive complesse**. Quindi si assumere una maggiore **sensibilità emotiva**, con cluster che riescono a catturare meglio la complessità dei sentimenti.

La capacità di **discriminazione tematica** migliora progressivamente: il modello specializzato riesce a separare meglio argomenti familiari, disturbi psicologici e relazioni romantiche in cluster distinti.

7 Conclusioni

Il progetto ha permesso di esplorare l'impiego di modelli di linguaggio generativo nel contesto della consulenza psicologica, valutandone le capacità di generare risposte empatiche, naturali e coerenti con il contesto clinico. Attraverso l'analisi delle metriche automatiche (cosine similarity, BERTScore, BLEURT e METEOR) è stato possibile osservare come il tipo di prompt potrebbe influenzare la qualità delle risposte.

In conclusione, i risultati ottenuti dimostrano il potenziale dei modelli linguistici nel supporto psicologico automatico, evidenziando l'importanza cruciale del prompt engineering nella definizione dello stile e della qualità delle risposte.

Bibliografia

- [1] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision (DSM-5-TR)*. American Psychiatric Association Publishing, Arlington, VA, 5th edition, 2022. Pubblicato a marzo 2022.
- [2] Amod. Mental health counseling conversations. https://huggingface.co/datasets/Amod/mental_health_counseling_conversations, 2023. Accessed: 2025-04-12.
- [3] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. Qlora: Efficient finetuning of quantized llms, 2023.
- [4] Qi Liu and Wanjing Ma. The epochal sawtooth phenomenon: Unveiling training loss oscillations in adam and other optimizers, 2025.
- [5] Nils Reimers and Iryna Gurevych. all-minilm-l6-v2. <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>, 2021. Accessed: 2025-04-18.
- [6] Gemma Team, Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Rivière, et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 2025.
- [7] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [8] Guan Wang, Sijie Cheng, Xianyuan Zhan, Xiangang Li, Sen Song, and Yang Liu. Openchat: Advancing open-source language models with mixed-quality data. *arXiv preprint arXiv:2309.11235*, 2023.
- [9] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, Guanting Dong, Haoran Wei, Huan Lin, Jialong Tang, Jialin Wang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Ma, Jin Xu, Jingren Zhou, Jinze Bai, Jinzheng He, Junyang Lin, Kai Dang, Keming Lu, Keqin Chen, Kexin Yang, Mei Li, Mingfeng Xue, Na Ni, Pei Zhang, Peng Wang, Ru Peng, Rui Men, Ruize Gao, Runji Lin, Shijie Wang, Shuai Bai, Sinan Tan, Tianhang Zhu, Tianhao Li, Tianyu Liu, Wenbin Ge, Xiaodong Deng, Xiaohuan Zhou, Xingzhang Ren, Xinyu Zhang, Xipin Wei, Xuancheng Ren, Yang Fan, Yang Yao, Yichang Zhang, Yu Wan, Yunfei Chu, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, and Zhihao Fan. Qwen2 technical report. *arXiv preprint arXiv:2407.10671*, 2024.